

Classificação da Qualidade de Vinhos

Como dados físico-químicos podem prever, antes da degustação, quais lotes têm mais chance de ser um vinho premiado


Tech Challenge — Fase 2 · POSTECH Data Analytics

Turma 14DTAT · Grupo 23 · Felipe Lins

1.143 vinhos tintos, 11 medições de laboratório cada

- Fonte: Wine Quality Dataset (Kaggle / UCI Machine Learning Repository).
- Cada amostra tem 11 medições físico-químicas (acidez, açúcar, cloretos, dióxido de enxofre, densidade, pH, sulfatos, teor alcoólico) e uma nota de qualidade de 3 a 8, atribuída por especialistas.
- Nenhum dado faltando — a base já chega limpa.
- Para simplificar a decisão de negócio, a nota foi convertida em duas categorias: **Alta Qualidade** (nota 7 ou 8) e **Baixa/Média Qualidade** (nota até 6).

Vinho de alta qualidade é raro: só 1 em cada 7



Apenas 13,9% dos vinhos da base (159 de 1.143) são "Alta Qualidade". Isso importa para a leitura dos resultados: um modelo "preguiçoso", que sempre dissesse "baixa/média", já acertaria 86% das vezes sem identificar nenhum vinho bom — por isso a análise não usa taxa de acerto geral como critério de sucesso (ver slide 6).

Três fatores puxam a nota para cima; um a puxa para baixo

- **Teor alcoólico** é o fator isolado mais associado a notas altas.
- **Sulfatos** e **ácido cítrico** também aparecem ligados a notas melhores — ambos contribuem para conservação e frescor do vinho.
- **Acidez volátil** é o principal fator negativo: em excesso, é o composto que dá gosto de vinagre — quanto maior, pior a nota tende a ser.
- Esses quatro fatores, sozinhos, já explicam boa parte da diferença entre um vinho premiado e um vinho comum na base analisada.

A SOLUÇÃO


Três modelos testados; o melhor acerta 69% dos vinhos bons

Modelo	Acerto geral	Vinhos bons encontrados (recall)	Confiabilidade do alerta (precisão)	Nota geral (F1)
Random Forest (escolhido)	89,5%	68,8%	61,1%	0,647
Gradient Boosting	90,4%	56,3%	69,2%	0,621
Regressão Logística	79,9%	68,8%	37,9%	0,489

Modelo escolhido: **Random Forest** — melhor equilíbrio entre encontrar os vinhos realmente bons e não gerar alarme falso em excesso, além do maior poder de discriminação entre as duas classes (medido por AUC-ROC = 0,90).

O QUE MAIS PESA NA DECISÃO DO MODELO

Teor alcoólico e sulfatos lideram — mesmo padrão da análise inicial



As variáveis mais usadas pelo modelo para decidir batem com o que a análise exploratória já indicava: teor alcoólico, sulfatos e o equilíbrio entre os dois tipos de acidez do vinho respondem por quase 40% do peso da decisão do modelo.

Três alavancas de produção para monitorar de perto

- **Controle de fermentação** — é o que define o teor alcoólico final, o fator isolado mais associado a notas altas.
- **Dosagem de sulfatos** — usados como conservante, aparecem de forma consistente ligados a vinhos mais bem avaliados dentro da faixa observada.
- **Prevenção de acidez volátil alta** — geralmente sinal de contaminação ou oxidação no processo, é o fator que mais puxa a nota para baixo.
- **Uso recomendado do modelo:** triagem — priorizar lotes com maior probabilidade de nota alta para avaliação sensorial detalhada, sem substituir a degustação humana.

O modelo funciona como triagem — e tem limites claros

- O modelo Random Forest encontra cerca de 7 em cada 10 vinhos realmente bons usando apenas medições de laboratório, sem degustação.
- Ele não substitui o especialista — serve para direcionar a atenção dele para os lotes mais promissores primeiro.
- A base é relativamente pequena e cobre só vinho tinto — o modelo precisa ser revalidado com mais dados (novas safras, outros tipos de vinho) antes de qualquer uso contínuo em produção.
- Próximo passo recomendado: rodar o modelo em paralelo com a avaliação humana por um período, comparando os resultados antes de qualquer decisão automática.